

Taller I

Pronósticos en Sección Cruzada y Ciclos

2026 - II

Instrucciones para la entrega:

1. El taller debe ser realizado y entregado en grupos de **3 o 4 personas**. No se aceptarán trabajos individuales ni grupos con un número de integrantes diferente al señalado.
2. La solución del taller debe entregarse de manera ordenada en **un único archivo PDF**. Cada punto debe presentarse siguiendo la numeración del taller, de menor a mayor.
3. Cada pregunta empírica debe estar acompañada por el **M-File o Do-File, según corresponda, y por la base de datos utilizada**. Los códigos deben ejecutar correctamente y permitir corroborar los resultados presentados en las respuestas.
4. Los M-File o Do-File deben estar organizados por secciones e incluir comentarios que expliquen claramente el paso a paso de los procedimientos realizados.
5. El archivo en PDF debe estar identificado al inicio con el **nombre y código de cada uno de los integrantes del grupo**. El PDF, los códigos y las bases de datos deberán entregarse dentro de **una única carpeta comprimida** al correo **szapata@uniandes.edu.co**, a más tardar el viernes **4 de septiembre de 2026**.

Pregunta 1. Pronósticos con variables exógenas y simulaciones

Usted quiere entender cómo realizar un pronóstico de corte transversal y empieza analizando los salarios de las personas en Estados Unidos con la información de la *National Longitudinal Survey of Youth 1979 (NLSY79)*.

La literatura de economía laboral ha estudiado extensamente si el ambiente familiar en la niñez —y no solo la dotación genética— afecta los resultados económicos en la adultez. Estudios que utilizan muestras de personas adoptadas^{1 2} encuentran que el entorno familiar de crianza sí tiene efectos significativos sobre variables como educación e ingresos. Inspirado en esta pregunta, usted quiere aproximar dicho efecto con los datos disponibles.

Para empezar su análisis usted toma una información filtrada y organizada, correspondiente a la ronda de encuesta de 2010 (los datos se encuentran en el archivo de Excel - *nlsy79_regresion*)³, que contiene la información individual del **nivel salarial por hora** (*Salario_Hora_USD*, en dólares), los **años de educación** (*Educacion_Anios*), la **edad** (*Edad_2010*), y una variable que aproxima si la persona **no creció con ambos padres biológicos a los 14 años** (*No_Ambos_Padres_Bio*: toma el valor 1 si la persona vivía con padrastro, madrastra, otro pariente, o solo uno de sus padres biológicos; toma el valor 0 si vivía con padre y madre

¹Sacerdote, B. (2007). *How Large Are the Effects from Changes in Family Environment? A Study of Korean American Adoptees*. Quarterly Journal of Economics, 122(1), 119-157.

²Björklund, A., Lindahl, M., & Plug, E. (2006). *The Origins of Intergenerational Associations: Lessons from Swedish Adoption Data*. Quarterly Journal of Economics, 121(3), 999-1028.

³Datos provenientes de la National Longitudinal Survey of Youth 1979 (NLSY79), Bureau of Labor Statistics de Estados Unidos, extraídos vía NLS Investigator: <https://www.nlsinfo.org/investigator>. Se utiliza la ronda de encuesta de 2010.

biológicos). Esta variable funciona como una aproximación (proxy) a la idea de "crianza fuera del hogar biológico" que motiva la literatura de adopción, aunque no equivale exactamente a adopción.

Adicionalmente, la base de datos incluye cuatro variables de control que usted deberá incorporar en el análisis: *AFQT_Percentil* (el puntaje percentil del respondiente en el Armed Forces Qualification Test, tomado en 1980, que funciona como una medida (proxy) de habilidad cognitiva); *Mujer* (variable dummy que toma el valor 1 si el respondiente es mujer y 0 si es hombre); e *Hispano* y *Negro* (variables dummy que toman el valor 1 si pertenece a dicho grupo étnico/racial, según el diseño muestral de la encuesta, y 0 en caso contrario). Estas cuatro variables son controles estándar en las ecuaciones de salarios (Mincer) y en los estudios de adopción citados, ya que la habilidad cognitiva, el género y el origen étnico/racial están asociados tanto con el salario como, potencialmente, con la estructura familiar de origen.

El problema radica en que no todas las personas que responden la encuesta reportan su nivel salarial y usted debe realizar la mejor predicción para completar los datos que están incompletos. Para eso usted cuenta con el siguiente modelo de predicción:

$$\ln(w_i) = \ln(w_0) + \beta_1 \cdot S_i + \beta_2 \cdot AFQT_i + \beta_3 \cdot Mujer_i + \beta_4 \cdot Hispano_i + \beta_5 \cdot Negro_i + \epsilon_i \quad [1]$$

Donde:

w_i : Es el nivel salarial por hora de la persona i , en dólares.

S_i : Es el número de años de escolaridad reportado por la persona i .

Nota: el modelo [1] no incluye la experiencia potencial como regresor. Al provenir todos los datos de una única ronda de encuesta (2010) con un rango de edad muy estrecho (45 a 53 años), la experiencia potencial ($\text{Edad} - \text{Educación} - 6$) queda casi determinada mecánicamente por los años de educación de cada persona, generando multicolinealidad severa. Por esta razón, en el análisis gráfico y en las estimaciones de esta sección se utiliza en su lugar el puntaje AFQT (*AFQT_Percentil*) como variable de comparación frente a la educación.

AFQT _{i} : Puntaje percentil en el Armed Forces Qualification Test de la persona i (proxy de habilidad cognitiva).

Mujer _{i} : Variable dummy que toma el valor 1 si la persona i es mujer, y 0 si es hombre.

Hispano _{i} , Negro _{i} : Variables dummy que toman el valor 1 si la persona i pertenece al grupo étnico/racial correspondiente, y 0 en caso contrario.

ϵ_i : Un error de medición en donde se pueden encontrar otras variables no observadas, tales como la localización geográfica, entre otras.

Preliminares

1. ¿Cuál es el pronóstico óptimo para el salario de la persona i ? Discuta los supuestos necesarios para que el pronóstico propuesto sea, de hecho, óptimo.
2. Usando las observaciones de la muestra (las que reportan salarios), haga diagramas de dispersión del logaritmo de los salarios con respecto a la educación y al puntaje AFQT (use el comando subplot de MATLAB para incluir varios gráficos en uno). Discuta qué espera de los parámetros del modelo en términos de signo y significancia.
3. Estime el modelo [1] por MCO. Reporte el R^2 y el $\bar{R}^2$ ajustado, e interpréte los desde una perspectiva de pronósticos.

4. Sin hacer simulaciones, pronostiquen el salario para los individuos que no lo reportan. Tenga en cuenta que, dentro del grupo de personas que no reportan salario, algunas tampoco reportan el puntaje AFQT (test de habilidad cognitiva) — como el modelo [1] requiere AFQT como regresor, usted debe eliminar de este ejercicio de pronóstico a las personas que no reporten AFQT, ya que para ellas no es posible calcular la predicción. Presente sus resultados en forma de gráfico de dispersión con el número de años de escolaridad en el eje horizontal y salario en el eje vertical.
5. Usando las observaciones de la muestra (las que reportan salarios), haga diagramas de dispersión del logaritmo de los salarios con respecto a la educación y al puntaje AFQT. A diferencia del numeral 2, en este numeral usted debe hacer 4 gráficos (use el comando subplot de MATLAB para incluir varios gráficos en uno):
 - a. Los dos primeros: salarios vs educación y salarios vs. AFQT diferenciando los puntos del gráfico entre personas con No_Ambos_Padres_Bio = 1 y No_Ambos_Padres_Bio = 0.
 - b. Los dos siguientes: salarios vs educación y salarios vs. AFQT diferenciando los puntos del gráfico por grupo racial/étnico de la persona (variable Raza).

Discuta los gráficos presentados y acompañado de diferentes estadísticas descriptivas comenten sobre las siguientes preguntas: ¿Cree que es importante incluir dichas características en la ecuación [1] para mejorar su pronóstico? ¿Cuál característica cree que afecta más el resultado del pronóstico, la estructura familiar de origen o el grupo racial/étnico de la persona?

6. Estime el modelo [1] dos veces: (a) tal como está especificado, agregando AFQT_Percentil, Mujer, Hispano y Negro como controles; y (b) agregando adicionalmente No_Ambos_Padres_Bio como regresor de interés. Compare ambas estimaciones reportando, para cada una, el coeficiente estimado de No_Ambos_Padres_Bio, su significancia, y el $\bar{R}^2$ ajustado. Con base en la literatura de adopción mencionada al inicio, discuta: ¿el signo y la magnitud del coeficiente de No_Ambos_Padres_Bio son consistentes con lo que encuentra dicha literatura? ¿Mejora el pronóstico al incluir esta variable, una vez controlado por habilidad (AFQT), género y origen étnico/racial?

Punto de bono extra:

Luego de leer el texto "Causation Does not Imply Variation" de John H. Cochrane⁴, relacione sus principales argumentos con el numeral anterior (numeral 6). En particular, explique por qué, aun cuando pueda identificarse una relación estadísticamente significativa entre la estructura familiar de origen (No_Ambos_Padres_Bio) y el salario, ello no implica necesariamente que el $\bar{R}^2$ del modelo aumente de forma considerable.

Intervalos y Densidades

Asumamos que después de la inspección gráfica realizada previamente usted decide realizar unos primeros pronósticos del salario siguiendo el modelo [1] completo, es decir, incluyendo Educación, AFQT, Mujer, Hispano, Negro y No_Ambos_Padres_Bio simultáneamente (según la especificación (b) del numeral 6 anterior), y solo para las personas que reportan salarios en la muestra. Para todas las simulaciones de esta sección, defina el perfil de la persona de referencia de la siguiente manera: las variables numéricas (Educación y AFQT) se fijan en su mediana muestral, y las variables

⁴Cochrane, J. H. (2025, 9 de noviembre). *Causation Does not Imply Variation*. The Grumpy Economist (blog). [Causation Does not Imply Variation - by John H. Cochrane](#)

categorías/dummy (Mujer, Hispano, Negro y No_Ambos_Padres_Bio) se fijan en 1, es decir, se pronostica para una persona que sí presenta cada una de esas características:

1. Asuma que $\varepsilon_i \sim N(0, \sigma^2)$. Sin hacer simulaciones, calcule un intervalo de confianza de 95% de confianza para su pronóstico. Reporte pronóstico puntual e intervalo inferior y superior de pronóstico.
2. Siga asumiendo que $\varepsilon_i \sim N(0, \sigma^2)$. Ahora construya un intervalo de confianza de 95% de confianza para su pronóstico usando $R = 50$, $R = 500$, $R = 10,000$. Compare los intervalos con los del intervalo teórico asumido en 1.
3. Grafique las simulaciones del punto 2, incluyendo punto, intervalo y densidad (use el comando subplot de MATLAB para incluir varios gráficos en uno).
4. Ahora suponga que no conoce la distribución de ε_i , excepto que estas tienen media cero. Construya un intervalo de confianza de 95% para su pronóstico asumiendo $R=10,000$.
5. Grafique las simulaciones del punto 4, incluyendo punto, intervalo y densidad. Compare gráficamente la densidad estimada y la distribución Normal. ¿Se justifica el supuesto de Normalidad?
6. Ahora, a la estimación realizada en el punto 4 agréguele incertidumbre en los parámetros (asuma normalidad de los parámetros). Construya un intervalo de 95% de confianza para su pronóstico asumiendo $R=10,000$ tanto para las repeticiones de ε como para las simulaciones de los parámetros.
7. Grafique las simulaciones del punto 6, incluyendo punto, intervalo y densidad. Discuta la importancia relativa de la incertidumbre en los parámetros comparada con la aleatoriedad de ε .
8. Finalmente, asuma que $\varepsilon_i \sim N(0, \sigma_i)$ —errores heteroscedásticos— y que existe incertidumbre en los parámetros (asuma normalidad de los parámetros). Construya un intervalo de 95% de confianza para su pronóstico asumiendo $R=10,000$ tanto para las simulaciones de ε como para las simulaciones de los parámetros.
9. Grafique las simulaciones del punto 8, incluyendo punto, intervalo y densidad. ¿Se generó algún cambio con respecto a las estimaciones del punto 6?

Pregunta 2

Considere el siguiente proceso estocástico para la brecha del producto (output gap) de una economía pequeña y abierta:

$$y_t = a_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

donde ε_t es un proceso ruido blanco con varianza σ^2 , y los parámetros satisfacen las condiciones de estacionariedad.

1. Encuentre la función de pronóstico óptimo s periodos adelante, $E_t(y_{t+s})$, en términos de y_t , y_{t-1} y los parámetros del modelo. Como ayuda, obtenga primero $E_t(y_{t+1})$, $E_t(y_{t+2})$ y $E_t(y_{t+3})$, e identifique el patrón recursivo antes de generalizar para un horizonte s .

- Defina el error de pronóstico s periodos adelante como $e_t(s) = y_{t+s} - E_t(y_{t+s})$. Muestre que $e_t(s)$ puede escribirse como una combinación lineal de los choques futuros $\{\varepsilon_{t+1}, \varepsilon_{t+2}, \dots, \varepsilon_{t+s}\}$, y derive explícitamente los coeficientes de esta combinación para $s = 1, 2, 3$.
- A partir del resultado anterior, encuentre $\text{Var}[e_t(s)]$ para $s = 1, 2, 3$. Analice cómo evoluciona la varianza del error de pronóstico a medida que aumenta el horizonte s . ¿Hacia qué valor converge $\text{Var}[e_t(s)]$ cuando $s \rightarrow \infty$? Relacione este resultado con la varianza incondicional de y_t y explique su interpretación económica.
- Encuentre $\text{Cov}[e_t(s), e_t(s-1)]$ y explique por qué los errores correspondientes a diferentes horizontes de pronóstico, construidos a partir de un mismo conjunto de información en t , pueden estar correlacionados. Posteriormente, considere dos errores de pronóstico al mismo horizonte s , pero construidos en momentos distintos, $e_t(s)$ y $e_{t+h}(s)$. Analice bajo qué condiciones estos errores estarán correlacionados y bajo cuáles serán incorrelacionados. En particular, relacione su respuesta con la existencia o no de choques futuros comunes en ambos errores de pronóstico.

Pregunta 3

Considere los siguientes tres procesos propuestos por distintos investigadores para modelar el componente cíclico del PIB trimestral de un país:

$$\text{Proceso I: } y_t = 1.6 y_{t-1} - 0.9 y_{t-2} + \varepsilon_t$$

$$\text{Proceso II: } y_t = 1.6 y_{t-1} - 0.63 y_{t-2} + \varepsilon_t$$

$$\text{Proceso III: } y_t = y_{t-1} + \varepsilon_t$$

- Para los Procesos I y II, calcule las raíces características de la ecuación homogénea asociada y clasifíquelas (reales o complejas conjugadas). Para el Proceso III, haga lo mismo.
- Para cada uno de los tres procesos, determine si es estacionario en covarianza, justificando con base en el módulo de las raíces encontradas en (1).
- Use la ecuación de recursión de Yule-Walker ($\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$) para calcular $\rho_1, \rho_2, \dots, \rho_8$ del Proceso I y del Proceso II. Grafique (a mano o describiendo la forma esperada) ambos correlogramas y compare: ¿cuál de los dos procesos exhibe autocorrelaciones que cambian de signo a medida que aumenta el rezago, y cuál no? Relacione esta diferencia con la naturaleza (real vs. compleja) de las raíces encontradas en (1).
- Ahora concéntrese en el Proceso III. Muestre que, a diferencia de los Procesos I y II, este proceso no tiene una función de autocorrelación teórica bien definida en el sentido usual (es decir, que ρ_k no converge a un valor fijo cuando k es grande, sino que $\rho_k \rightarrow 1$ para cualquier k fijo a medida que crece el tamaño de la muestra, un síntoma característico de no estacionariedad). Explique por qué esto hace que el Proceso III sea inadecuado para representar un componente estrictamente cíclico del PIB, y qué transformación simple lo convertiría en un buen candidato para dicho fin.

Pregunta 4

Preliminares

En el archivo de excel denominado tributarios se encuentra la serie mensual de los ingresos tributarios, en miles de millones de pesos, de Colombia desde enero de 2004⁵. Por el momento, suponga que la variación logarítmica de esta variable sigue un proceso AR(2):

$$\Delta y_t = c + \theta_1 \Delta y_{t-1} + \theta_2 \Delta y_{t-2} + \varepsilon_t \text{ donde } \varepsilon_t \text{ es un proceso ruido blanco y } \Delta y_t = \ln y_t - \ln y_{t-1}$$

- Para la serie del Tributarios(SA) realicen los siguientes procedimientos:

⁵ La serie tributarios proviene del Ministerio de Hacienda, la serie Tributarios (SA) son los ingresos tributarios ajustado por estacionalidad, este último es una estimación realizada con X-13ARIMA-SEATS.

1. Conviertan la serie del Tributarios(SA) a logaritmo natural, estime su primera diferencia y describa sus principales características (asegúrense de multiplicar por 100 este valor para interpretar todos los resultados como variación porcentual mensual)⁶.
2. Estimen y grafiquen las 20 primeras autocorrelaciones de la primera diferencia logarítmica de los ingresos tributarios (SA) e Interpreten los resultados.
3. Estimen y grafiquen las 20 primeras autocorrelaciones parciales de la primera diferencia logarítmica de los ingresos tributarios (SA) e interpreten los resultados.
4. Estimen los parámetros c y θ por MCO, tomando como variable endógena la primera diferencia del logaritmo natural de los ingresos tributarios (SA).
5. Realicen un pronóstico condicional a 18 períodos de la variación mensual de los ingresos tributarios desestacionalizados (SA), utilizando el modelo AR(2) estimado por MCO. A partir de estos pronósticos, transformen la serie proyectada para obtener el nivel mensual de los ingresos tributarios en términos nominales entre julio de 2026 y diciembre de 2027. Posteriormente, calculen el recaudo total anual proyectado para 2026 y 2027, sumando los valores mensuales correspondientes a cada año, y comparen el recaudo de 2026 frente a 2025 y el de 2027 frente a 2026, calculando en cada caso tanto la diferencia nominal como la variación porcentual. Finalmente, analicen sus resultados.

Autoarima

Ahora, usando la serie de la primera diferencia del logaritmo de los ingresos tributarios (SA), suponga que esta serie sigue un proceso ARMA:

$$y_t = \frac{\Theta(L)}{\Phi(L)} \varepsilon_t$$

1. Estime el componente cíclico y justifique su estimación con estadísticas y criterios de información del modelo estimado.
2. Construya y grafique la serie de residuales. Justifique que se trata de ruido blanco.
3. Documente pruebas de normalidad y aquellas relevantes para justificar los supuestos de su modelo.
4. Construya una gráfica en la que el eje x serán todos los meses del año 2024 y 2025, en donde se presente la primera diferencia del logaritmo natural de los ingresos tributarios (SA) por cada mes observado y su pronóstico desde julio de 2026 hasta diciembre de 2027.
5. Con base en sus estimaciones, construyan el pronóstico del nivel de los ingresos tributarios para 2026 y 2027 y calculen el recaudo total proyectado para cada uno de estos años. ¿Cuál es su estimación del total de ingresos tributarios para 2026 y para 2027? Compárenla con la última proyección disponible del Ministerio de Hacienda y Crédito Público (MHCP), según la cual los ingresos tributarios ascenderían a \$294,2 billones en 2026 y a \$308,9 billones en 2027; este último valor no incorpora el ajuste de \$30,2 billones incluido en el MFMP 2026. ¿Qué tan cercanas o alejadas están sus estimaciones de las proyecciones del MHCP? A partir de esta comparación, discutan si consideran que las proyecciones del Ministerio son optimistas, realistas o pesimistas y sustenten su respuesta.

⁶ Recuerde que ante variaciones muy pequeñas de una serie la diferencia del logaritmo natural es aproximadamente igual a la variación porcentual.